

Especificação do Trabalho prático 2018/2 e 2019/2

O trabalho consiste na criação de um programa, em linguagem C, capaz de indexar palavras de um ou mais documentos de texto. Tal programa deverá ser nomeado como `indexer`.

Arquivos para testes

- <http://200.236.3.126:8999/ds141-texts/>

Funcionamento

NOME

`indexer` - indexa palavras de documentos de texto

SINOPSE

```
indexer --freq N ARQUIVO
indexer --freq-word PALAVRA ARQUIVO
indexer --search TERMO ARQUIVO [ARQUIVO ...]
```

DESCRIÇÃO

O programa `**indexer**` realiza uma contagem de palavras em documentos de texto. A partir dessa contagem, ele ainda permite uma busca pelo número de ocorrências de uma palavra específica em um documento, ou a seleção de documentos relevantes para um dado termo de busca.

O programa `**indexer**` transforma todas as letras para minúsculas e ignora caracteres como números e pontuações.

Quando executado com a opção `--freq`, o programa `**indexer**` irá exibir o número de ocorrências das N palavras mais frequentes no documento passado como parâmetro, em ordem decrescente de ocorrências.

Quando executado com a opção `--freq-word`, o programa `**indexer**` exibe a contagem de uma palavra específica no documento passado como parâmetro.

Por fim, quando executado com a opção `--search`, o programa `**indexer**` apresenta uma listagem dos documentos mais relevantes para um dado termo de busca. Para tanto, o programa utiliza o cálculo TF-IDF (Term Frequency-Inverse Document Frequency).

OPÇÕES

`--freq N ARQUIVO`

Exibe o número de ocorrência das N palavras que mais aparecem em ARQUIVO, em ordem decrescente de ocorrência.

`--freq-word PALAVRA ARQUIVO`

Exibe o número de ocorrências de PALAVRA em ARQUIVO.

`--search TERMO ARQUIVO [ARQUIVO ...]`

Exibe uma listagem dos ARQUIVOS mais relevantes encontrados pela busca por TERMO. A listagem é apresentada em ordem decrescente de relevância.

TERMO pode conter mais de uma palavra. Neste caso, deve ser indicado entre âspas.

Requisitos

O trabalho deve ser realizado em grupos de até 2 alunos.

O programa deve conter a implementação de uma estrutura de dados eficiente capaz de atender às funcionalidades descritas acima, mesmo quando executado com arquivos grandes (> 1GB). Tal estrutura deve ser implementada pelos próprios alunos e deverá ser explicada no dia da defesa do trabalho.

O programa deve ser capaz de ser compilado e executado em um ambiente Linux. Isso não deve gerar maiores problemas para aqueles que programam em Windows ou outro S.O.. Basta ter cuidado para não utilizar bibliotecas ou outras diretrizes específicas desses S.O.'s.

Além disso, o programa deverá ser acompanhado de um Makefile (sugestão sobre o tema https://pt.wikibooks.org/wiki/Programar_em_C/Makefiles).

Como informado acima, o funcionamento da aplicação **indexer** tem as seguintes peculiaridades: - Transformar todas os caracteres em minúsculo, ou seja, comportamento de *ignore-case*; - Ignorar caracteres que não sejam letras, como números e pontuações: - Por conta disso, palavras compostas como **bem-vindo** serão separadas em duas, **bem** e **vindo**.

Entrega e Defesa

A avaliação do trabalho será composta pela entrega do código-fonte e de uma defesa.

A defesa será realizada por meio de um vídeo gravado, com a participação de todos os integrantes do grupo (pode ser apenas voz), demonstrando a aplicação em funcionamento. Durante o vídeo, deve ser descrita e justificada a estrutura de dados utilizada e apresentado de maneira breve o código-fonte. O vídeo deve ter no máximo 10min.

A entrega será realizada por meio da criação de um repositório no gitlab (enviar endereço do repositório por tarefa no moodle). A data da entrega será definida no moodle da disciplina.

Basicamente, vou clonar o repositório recebido, executar o comando **makee** a partir daí, um programa chamado **indexer** já deve estar disponível para que eu inicie testes em minha máquina.

Caso eu não seja capaz de compilar e executar o trabalho na minha máquina, a nota máxima será 50.

Data da entrega: 13/08/2021 pelo moodle da disciplina.

Cálculo de Relevância

O cálculo para determinar a relevância de um texto para um dado termo de busca deve ser realizado utilizando a técnica **Term Frequency-Inverse Document Frequency** (<https://pt.wikipedia.org/wiki/Tf-idf> e https://en.wikipedia.org/wiki/Tf-idf#Term_frequency).

Term Frequency (TF) ou Frequência de um termo t , deve ser calculada como o número de vezes que t aparece no documento, dividido pelo número total de palavras no documento:

$$TF(t,d) = (\text{Número de vezes que } t \text{ aparece em } d) / (\text{Total de palavras em } d)$$

Inverse Document Frequency (IDF) ou Frequência inversa de documento para um conjunto de documentos D é o logaritmo da divisão do número total de documentos pelo número de documentos que contém o termo t em questão:

$$IDF(t,D) = \log [(\text{Número de Documentos}) / (\text{Número de documentos em que } t \text{ está presente})]$$

Logaritmo de base 10.

Por fim, TFIDF é a multiplicação das duas medidas. Ela indica qual a relevância de um termo t para um documento d dentre uma coleção de documentos D :

$$TFIDF(t,d,D) = TF(t,d) * IDF(t,D)$$

Para termos com mais de uma palavra, deve ser calculado a média entre o TF-IDF de cada palavra.

Mais uma referência: <http://www.tfidf.com>